



C2p: Why can CLIP features be used for general deepfake detection with linear classifiers?

总结：CLIP、DINO 和 MAE 都包含可迁移的伪造相关信息，但 CLIP 更倾向于将这些信息集中在少数、共享、且更易被线性读出的方向中，因此它最适合用简单线性分类器完成泛化伪造检测。


1. 在统一训练协议下，不同预训练 backbone 的泛化 deepfake detection 能力是否有差异



图：不同 backon 在 auc 上的测试 (test)




图：不同 backon 在 auc 上的测试 (9gan)




图：不同 backon 在 auc 上的测试 (扩散)


2. 这些差异是性能差异，还是表示空间中的线性可读性差异？（比较 linear probe 和 mlp probe）



图：test 测试集测试



图：9gan 测试集测试



图：扩散集验证

Backbone (clip) 的 MLP 相比 linear 提升很小，说明其伪造信息已经在线性层面充分暴露，如果提升大，说明信息虽存在，但未被线性充分展开(dinov2,mae)

这提示我们，backbone 之间的关键差异不只是是否包含伪造信息，而是这些信息在表示空间中是否已经被线性展开。

3. 为什么 CLIP 的伪造信息更容易被线性读出来--线性可读是否与 source 的共享方向有关？一个表示适合做 general deepfake detection，它的 fake-real direction 是否应该在不同伪造源之间更一致？

$ds = \mu_{fake,s} - \mu_{real,s}$ (检验不同 backbone 是否把不同伪造源的 fake-real difference 组织成更共享的方向。不同 source 的真假分离，是不是沿着相似的几何方向反生)

Fig 4B - Source direction (clip, forensynths_test)




Fig 4B - Source direction (dinov2, forensynths_test)




Fig 4B - Source direction (mae, forensynths_test)





Fig 4B - Source direction (vit, forensynths_test)



图：不同 backbone 在 test 上热力图

Fig 4B - Source direction (clip, 9gan)







Fig 4B - Source direction (dinov2, 9gan)





图：不同 backone 在 9gan 上热力图



图：不同 backone 在扩散模型上热力图

在 9gan 中效果最为明显：


CLIP 的跨生成模型两两相识度更高, DINO 也有较强共享结构, MAE / ViT 效果不好。

CLIP 的不同伪造源之间具有更一致的 fake-real direction; DINO 次之, MAE 与 ViT 更分散。


共享方向的一致性只是间接证据；它说明 CLIP 倾向于学习 source-agnostic 的 fake-real structure，但尚不能回答这些结构是否已集中在少数可直接线性利用的方向中。

4.为什么线性头就足够了？如果 CLIP 真的更线性可读，那么它的判别信息是否应该集中在少数高度有用的方向里？


How fast top-k directions approach best observed linear performance (ForenSynths)



How fast top-k directions approach best observed linear performance (9 GANs)




How fast top-k directions approach best observed linear performance (Diffusion)



图：模型到达最佳性能要多少个方向

How many forgery directions are needed to reach 95% of best observed linear performance



图：模型需要的平均方向

该实验直接表明：CLIP 的最佳线性判别能力可以由一个更低维的判别子空间近似恢复，而 DINO、MAE 和 ViT 需要更大的子空间才能接近各自的最佳线性性能。这说明 CLIP 的伪造信息并非只是存在，而是以更紧凑、更集中、更线性可读的方式被组织在表示空间中。

$$k_{95} = \min\{k: \text{AUC}(k) \geq 0.95 \cdot k' \cdot \max \text{AUC}(k')\}$$

为了让模型的检测能力达到它自身最高水平的 95%，最少需要用到前 k 个特征方向