

二、 实验分析

实验分析 1：分类头 vs. LoRA 微调的作用辨析

1. 实验设置

训练数据：仅包含 4 类（Car, Cat, Chair, Horse）的 GAN 生成图像

模型架构：DINOv2（ViT-L/14）与 CLIP（ViT-L/14）

微调策略：NoLoRA：冻结骨干网络，仅训练分类头。

LoRA：微调 Attention 层（q, k, v, proj）+ 训练分类头。

AllLoRA：微调 Attention 层 + MLP 层 + 训练分类头。

微调系数：rank=8, alpha=16(均设置一致)

测试数据：Test：同类生成器（BigGAN, CycleGAN 等）。

Cross-Model GAN (9GAN)未见过的 GAN 架构（AttGAN, BEGAN 等）。

Cross-Gen Method (Universal)：扩散模型生成的图像（DALLE, GLIDE 等，仅 CLIP 测试）。

分类头：1. **Linear head**:只有一个线性分类头

2. **Mlp**: nn.Linear(self.feature_dim, 512),

nn.ReLU(),


nn.Dropout(0.3),

nn.Linear(512, 1)


3.**transmlp**:transformer 的 FFN 层：

```
self.c_fc    = nn.Linear(config.n_embd, 4 * config.n_embd, bias=config.bias)
self.gelu    = nn.GELU()
self.c_proj  = nn.Linear(4 * config.n_embd, config.n_embd, bias=config.bias)
self.dropout = nn.Dropout(config.dropout)
```


- Test 测试图表:




Dinov2 在 Test 上的准确率




Dinov2 在 GANGen-Detection 上的准确率



CLIP 在 Test 上的准确率



CLIP 在 GANGen-Detection 上的准确率



CLIP 在 UniversalFakeDetect_test 上的准确率

实验结果分析：

1. DINOv2 实验结果分析

- **NoLoRA 的局限性：**

在 nolora 设置下，无论使用 Linear 还是 MLP 分类头，DINOv2 在 Test 集上的准确率均徘徊在 74%-78%，在 9GAN 上也仅为 74%-76%。这表明 DINOv2 原始的预训练特征空间虽然具备一定的表征能力，但其语义主导的特征分布并未针对伪造检测任务实现最佳的线性可分性，仅靠调整分类头无法突破性能瓶颈。

- **LoRA 对特征空间的显著重塑：**

引入 lora（仅微调 Attention）后，性能出现显著跃升。特别是在结合 transmlp 头时，Test 集准确率达到 **87.22%**，9GAN 集达到 **87.16%**。这证实了通过低秩适应微调 Attention 层，模型成功将特征关注点从单纯的物体语义转移到了具有鉴别性的伪影特征上，实现了约 **10%** 的绝对性能提升。

- **AllLoRA 与复杂分类头的过拟合风险:**

值得注意的是，在 allora（微调 Attention + MLP）设置下，虽然 Linear 和 MLP 头表现尚可，但 transmlp 头出现了严重的性能衰退（9GAN 上跌至 67.73%）。这表明在小样本（4 类）训练下，**过多的可训练参数（AllLoRA + TransMLP）导致了模型对训练数据的过拟合，损害了模型在未见生成器上的泛化能力。**

2. CLIP 实验结果分析

- **极高的 Zero-Shot (Strong Baseline):**

CLIP 的 nolora 已表现很好，在 Test 上达到 86~87%，在 9GAN 上甚至达到 93-95%。这说明 CLIP 经过海量图文对预训练后，其特征空间本身就比 DINOv2 更紧凑且具备更强的鲁棒性，“真”与“假”在原始空间中已经具备较好的可分性。（我推测 clip 模型预训练的时候就已经学习过互联网图像的‘真’与‘假’这些丰富的图片描述，从而对齐了关于图像真实性的先验知识）

- **LoRA (Attention-only) 优于 AllLoRA:**

与 DINOv2 不同，CLIP 在 lora 设置下通常达到峰值（Test: **94.06%**，9GAN: **98.11%**），而在 allora 设置下性能反而普遍下降（例如 Test 上 Linear 头从 94.06% 降至 86.19%）。

这表明对于 CLIP 而言，其 MLP 层中存储的先验知识对于判别任务至关重要。使用 AllLoRA 修改 MLP 层可能会**破坏 CLIP 原有的预训练知识结构**，反而不如只调整 Attention 层（改变关注点）效果好。

- **跨生成机制的泛化能力：**

在 clip-univer-acc 中，尽管训练数据全为 GAN 生成，但 CLIP 在 lora-linear 设置下对扩散模型的检测准确率达 **83.02%** 远高于 nolora 的 72.81%。

这一结果有力地证明了：**微调后的 CLIP 模型学习到了一种跨越生成机制的“通用伪影表征”** 这种表征不依赖于 GAN 特有的效应，而是捕捉到了生成模型共有的高频异常或结构不一致性。

3. 综合对比与核心发现

1. 特征空间重塑的主导地位：

对比 NoLoRA 和 LoRA 的数据，证明了分类头的复杂度（**Linear vs TransMLP**）对性能的影响远小于微调骨干网络的影响。性能的质变源于 LoRA 将特征空间中的真假样本拉开，而非分类边界的非线性拟合。

2. CLIP 的架构优势与 DINOv2 的局限：

CLIP 在所有测试集上均显著优于 DINOv2。数据表明，CLIP 的 Text-Image 对齐预训练为伪造检测提供了更稳固的**语义锚点**。DINOv2 在 9GAN 上的表现（最高 ~87%）远低于 CLIP（最高 ~98%），且未测试 Universal 集合，是因为其在同域 GAN 上的泛化性已显不足，难以应对分布差异更大的扩散模型。

3. 微调深度的敏感性差异（LoRA (qkv,proj) vs AllLoRA(qkv,proj,mlp)）：

- **DINOv2** 受益于更深度的微调（倾向于 AllLoRA 或复杂的 Head），因为它需要大幅度重塑特征空间。
- **CLIP** 倾向于轻量级微调（LoRA > AllLoRA），因为它主要需要调整注意力机制而非重写知识库。过度的微调（AllLoRA）在 CLIP 上会导致负迁移。

4. 从小数据到通用检测的实证：

仅使用 4 类简单物体（Car, Cat, Chair, Horse）训练，CLIP + LoRA 能够在 Test (94%)、9GAN (98%) 和 Universal (83%) 上取得优异成绩。这在数据层面上证实了核心假设：**模型并未过拟合于特定的物体类别，而是成功解耦了“语义内容”与“伪造痕迹”，实现了真正的伪造检测泛化。**

实验分析 2：微调后模型关注点的根本性转移

为了探究 LoRA 微调如何改变大模型的特征表示，我在未见过的 BigGAN 数据集上进行了基于余弦相似度的图像检索实验。通过对比 Frozen（冻结基座）与 LoRA（微调）模型在给定查询图像（Query）时的 Top-K 检索结果，我观察到了特征关注点的根本性转移

1. 语义特征的解耦与伪影特征的对齐

- 证据图表：

Dinov2在biggan大数据集上抽取2000张进行查询对比—大数据集

给定一个真图查询



使用一个真图 Q 在 biggan 数据上查询（模型为 dinov2，上为冻结，下为微调）

Dinov2在biggan大数据集上抽取2000张进行查询对比—大数据集



给定一个假图进行查询



使用一个假图 Q 在 biggan 数据上查询（模型为 dinov2，上为冻结，下为微调）

分析：

1.DINOv2:

Frozen DINOv2 的表现:

如检索图所示，未微调的 DINOv2 表现出强烈的语义内容偏置。当查询图像为一只“假猫”时，检索结果主要由“猫”的图像组成（Top-1 至 Top-5 均为猫），且混杂了真实图像（绿框）与伪造图像（红框）。相似度分数较低（~0.4-0.6），且模型无法有效区分真伪。这表明原始 DINOv2 的特征空间主要由物体类别主导，缺乏对生成伪影的敏感性。

LoRA DINOv2 的表现:


引入 LoRA 后，特征空间发生了剧烈的变化。

跨类别检索现象：当查询图像为“假猫”时，LoRA DINOv2 检索出的 Top-K 结果全为伪造图像（红框），但其语义内容发生了显著漂移，包含了“假包”、“假护具”等非猫类物体。


分析：这一现象证实了语义解耦的发生。LoRA 微调迫使模型抑制了高层语义特征（如“猫”的形状），转而极度关注底层生成的伪影特征。在微调后的特征空

间中，不同类别的伪造图像因具有相似的生成痕迹（如高频噪声、局部纹理畸变）而被聚类在一起。这也解释了为何 DINOv2 能在训练类别之外实现泛化，但也导致了其在特征空间中对假图的表征具有较大的方差。

使用一个真图在biggan(随机抽取2000张进行计算相似度来查询) --大数据集



使用一个假图在biggan(随机抽取2000张进行计算相似度来查询) --大数据集



使用一个假图 Q 在 biggan 数据上查询（模型为 clip，上为冻结，下为微调）

分析：

2.CLIP:

Frozen CLIP 的表现:

与 DINOv2 类似，Frozen CLIP 在检索时同样由语义主导。给定真图或假图查询，返回的均是同类别的物体，真假样本在特征空间中高度重叠，缺乏可分性。

LoRA CLIP 的表现:

微调后的 CLIP 展现出与 DINOv2 截然不同的行为模式。

语义一致性保持：在给定“假车”作为查询时，LoRA CLIP 检索出的结果不仅均为伪造图像（红框），且在视觉上保留了较高的结构相似性（如白色的车身、类似的场景结构）。它没有像 DINOv2 那样出现完全的语义崩塌。

机理分析：这表明 CLIP 的特征重组是在保留语义锚点的前提下进行的。得益于预训练时的文本监督，CLIP 的特征空间具备更强的结构约束。LoRA 微调并

没有完全抹除物体语义，其在测试集上更高的分类准确率和更强的鲁棒性

3.结论:

综合对比 DINOv2 和 CLIP 的检索可视化结果，可以得出以下结论:

1. **LoRA 的本质作用:** LoRA 微调并非简单的边界调整，而是驱动模型特征提取重心的转移——从以内容为中心转移至以真假性为中心
2. **模型行为差异:**
 - **DINOv2** 倾向于学习“类无关的通用伪影”，导致特征空间中语义信息的丢失。
 - **CLIP** 倾向于学习“语义感知的伪影表征”，利用语言先验知识约束特征分布，使得真假样本在特征空间中的分离更加有序和鲁棒

实验分析三：注意力机制转移与特征维度偏移的可视化验证

- 证据图表：



DINOv2 可视化效果图

分析：

1.DINOv2:

Frozen DINOv2 的注意力分布：

观察 Dinov2 可视化效果图（第一行 Car 和第二行 Cat），未微调的 Frozen DINOv2 的高响应区域（绿色高亮部分）高度集中在具有明确语义信息的物体主体区域。

在 prognan-car 样本中，热力图聚焦于车头、挡风玻璃等定义“汽车”类别的关键部件。

在 prognan-cat 样本中，注意力主要集中在猫的眼部、鼻部等面部特征，这符合预训练模型用于物体识别的特征提取逻辑，即寻找最具判别性的语义特征。


LoRA DINOv2 的注意力重定向：

引入 LoRA 微调后，模型的注意力分布发生了根本性的重构。

边缘与纹理偏好：热力图不再聚焦于物体的主体语义中心，而是显著扩散至物体边缘和背景区域。例如，在假猫图像中，高响应区转移到了猫的毛发纹理细节和面部边缘；在假车图像中，关注点偏移至车身轮廓及光影反射区域。

伪影特征捕捉：这种注意力的发散并非随机，而是对应了 GAN 生成图像中常见的高频伪影和结构不一致性所在的区域。实验结果表明，LoRA 成功引导模型抑制了对“物体是什么”的语义响应，转而增强了对“图像是如何生成的”即伪造痕迹的敏感度。

Clip可视化，发生特征维度的偏移



CLIP 可视化效果图



Clip 查询图 (dire_googledrive/sdv1_new/bedroom/1_fake/1.png)

分析:

2.CLIP:

我选取一张伪造的卧室图像 (Image: dire_googledrive/sdv1_new/bedroom/1_fake/1.png) 作为输入, 构建了两组文本提示词:

1. **语义概念组:** 如 "a photo of a tidy bedroom", "interior design".
2. **取证/伪造概念组:** 如 an ai generated image with artifacts "distorted furniture", "gan generated image", "deepfake bedroom".

通过计算图像特征与文本特征的余弦相识度, 量化特征空间的偏移。

Frozen CLIP:

如图表蓝色柱状图所示, Frozen CLIP 在“语义概念组”上表现出极高的置信度 (例如 "a photo of a tidy bedroom" 概率 > 0.30), 而在“取证概念组”上的匹配概率接近于零。这表明原始 CLIP 模型完全基于图像的内容语义进行编码, 无法识别图像的伪造属性。

LoRA CLIP:

LoRA CLIP (橙色柱状图) 的匹配分布出现了显著的**维度偏移**:

语义维度的抑制: 模型对单纯描述场景内容的文本 (如 "a photo of a tidy bedroom") 的匹配概率出现明显下降, 但并未完全消失, 说明模型仍保留了基础的场景理解能力。

伪造维度的激活: 在描述伪造属性的文本上, 匹配概率呈现爆发式增长。例如, 对 "distorted furniture and warped edges"和 "an ai generated image with artifacts" 的匹配概率显著提升。

结论: 这定量地证实了 LoRA 微调将图像的特征向量在嵌入空间中进行了方向性的修正。修正后的特征向量不仅仅编码了“这是一间卧室”, 更重要的是编码了“这是一张由生成模型合成、具有扭曲特征的图像”。这种语义-伪影双重表征正是 CLIP 在伪造检测任务中表现优异的核心原因。

实验分析四：DINOv2 与 CLIP 的深层差异

为了评估模型在面对多源异构生成数据时的泛化边界，我在 test 数据集上计算了特征向量的余弦相似度统计指标。

指标定义与物理含义：

Intra-Real (类内-真): 真实图像样本间的平均余弦相似度。该值越高，表示真实样本在特征空间中的分布越紧凑。

Intra-Fake (类内-假): 伪造图像样本间的平均余弦相似度。该值反映了模型提取的伪造特征在不同生成器（如 BigGAN 与 DeepFake）间的一致性。

Inter(R-F) (类间-真假): 真实样本中心与伪造样本中心之间的余弦相似度。该值越低（甚至为负），表示真假两类在特征空间中的距离越远，正交性或对立性越强。

Gap (分离度): 计算公式为 $\text{Intra(Avg)} - \text{Inter(R-F)}$ 。该指标综合衡量了类内紧凑度与类间分离度，直接反映了线性分类边界的构建难度

图表：

Model Configuration	Intra(Real)	Intra(Fake)	Intra(Avg)	Inter(R-F)	Gap (Sep)
DINOv2 (Base)	0.0245	0.0676	0.0461	0.0299	0.0162
DINOv2 (LoRA)	0.4438	0.2637	0.3538	-0.0387	0.3925
CLIP (Base)	0.2731	0.3342	0.3036	0.2627	0.0410
CLIP (LoRA)	0.4217	0.4527	0.4372	0.1028	0.3344

在 Test（biggan,cyclelegan 等）上测试真假图余弦相识度

结论：

1.基座模型分析：

DINOv2 (Base):

Intra(Real)(0.0245)和 Inter(R-F)(0.0299) 均处于极低水平且数值接近。这表明在原始 DINOv2 空间中，样本呈现近似正交的高维均匀分布，缺乏针对“真/假”属性的聚类结构，导致 Gap 仅为 0.0162，难以进行有效区分。

CLIP (Base):

Inter(R-F)高达 0.2627，且与 Intra(Real)(0.2731)接近。这证实了 CLIP 的原始特

征空间主要由语义主导，真图与其对应的假图（如真猫与假猫）因语义相似而距离较近，导致特征纠缠，缺乏区分真伪的判别性边界。

2. LoRA 微调对特征空间的重塑作用

引入 LoRA 微调后，两种模型的 Gap 值均实现了数量级的提升（DINOv2: $0.0162 \rightarrow 0.3925$; CLIP: $0.0410 \rightarrow 0.3344$ ），证明了微调成功将特征流形从语义主导重塑为真实性主导。

3. DINOv2 与 CLIP 的拓扑结构差异分析

DINOv2：基于排斥机制的离群分布

负类间相似度：DINOv2 (LoRA)的 Inter(R-F)降至**-0.0387**。负值表明真实样本向量与伪造样本向量在方向上呈现近似背离的状态。

较低的伪造类内紧凑度：尽管 Intra(Real)提升至 0.4438，但 Intra(Fake) 仅为 0.2637。考虑到 test 数据集包含从 BigGAN 到 StyleGAN2 等多种生成器，较低的说明 DINOv2 将不同的伪造类型映射到了特征空间中较为分散的区域。

结论：DINOv2 的判别机制倾向于构建一个紧凑的“真实域”，并将所有不符合真实分布的样本（即假图）排斥到空间的边缘。它虽然实现了最大的分离度（Gap 最大），但并未形成一个统一的“伪造概念”簇。

CLIP：基于语义锚点的紧凑聚类

最高的伪造类内紧凑度：CLIP (LoRA)的 Intra(Fake)达到了 **0.4527**，显著高于 DINOv2，甚至高于其自身的 Intra(Real)(0.4217)。

结论：这是一个很好的现象。尽管 test 数据集中的图像生成原理各异，CLIP 依然成功将它们在特征空间中高度聚类。这表明 CLIP 学习到了一种**通用伪造表征**。得益于预训练的图文对齐先验，CLIP 将具有不同视觉伪影的样本映射到了同一个高维语义簇中（即“人工生成的图像”），从而保证了其在面对未见生成器时具有更强的鲁棒性。

总结

通过对比 Intra-Fake 和 Gap 指标，证实了两种模型在处理异构测试数据时的不同机理：

- **DINOv2 (LoRA)**采用“排斥策略”：拉大真假距离（最大化 Gap），但对不同伪造类型的特征整合能力较弱（低 Intra-Fake）。
- **CLIP (LoRA)**采用“聚类策略”：利用语义先验将异构的伪造数据映射为紧凑的特征簇（高 Intra-Fake），构建了具有明确语义边界的伪造检测空间