

一、实验模型扩展

在原有 CLIP 与 DINOv2 的基础上，本阶段新增了 BLIP , DINOv3, MAE , ViT 四种具有代表性的架构进行对比。模型均采用 **Vit-Large**

选取理由：这五种模型包含了有监督 vs 无监督、生成 vs 判别、单模态 vs 多模态

总体性能排名：所采用的训练与测试数据与上次相同都是（NPR 训练+测试数据）

1. **同源测试 (Test/ForenSynths):** CLIP $\approx$ DINOv3 > DINOv2 > BLIP > MAE > ViT
2. **跨生成器泛化 (9GAN):** CLIP > DINOv3 > DINOv2 > BLIP > ViT > MAE
3. **跨机制泛化 (Diffusion/Uni):** DINOv3 > CLIP > DINOv2 $\approx$ BLIP > MAE > ViT

观察：

DINOv3 的测试强劲：DINOv3 在所有测试中表现强劲，特别是在最难的 Diffusion 泛化上超越了 CLIP。若使用 7B 版本，其性能更是全面碾压，这暗示了特征判别性与模型规模的好处。（显卡不足，跑不了 7B 版本，我使用的 dinov3-Large-M 级别的已和 clip 相当，部分性能已经超越，使用 7B 应该效果会更好）

MAE 与 ViT 的颓势：纯像素重建（MAE）和纯监督分类（ViT）的模型在泛化性上显著弱于图文对齐（CLIP）和自监督学习（DINO 系列）。

二、观点提出

模型对比分析：预训练目标对特征空间的重塑

基于不同的预训练目标，将模型分为三类进行机理剖析：

1. 语义主导型（CLIP, BLIP）

表现：泛化性极强（CLIP 在 9GAN/Uni 上表现优异）。

BLIP 的特异性：BLIP 虽有文本监督，但其 Decoder 结构旨在生成描述，导致其 Encoder 对“判别性特征”的压缩能力弱于 CLIP。BLIP 在微调后虽然保留了语义，但对微小伪影的敏感度不如 CLIP 锐利。

机理：语言先验为特征空间提供了“正交约束”，使得伪影特征不会侵蚀语义特征，形成了规则的分布。

2. 判别自监督型（DINOv2, DINOv3）

表现：DINOv3 展现了最强的潜力。

DINOv2 采用排斥策略（推远假图），导致类内方差大。DINOv3 改进了训练策略，使其

特征空间在保持高判别性的同时，具备了类似 CLIP 的聚类紧凑性（从 Intra-Fake 数据可佐证）。

DINOv3 强于 CLIP 的原因：在 Diffusion 数据集上，CLIP 可能受限于文本描述的粒度，而 DINOv3 纯视觉的细粒度特征更能捕捉 Diffusion 生成图像中微妙的结构坍塌。

3. 像素/分类重建型 (MAE, ViT)

表现：效果数据垫底。MAE 的预训练目标是猜像素。在它的特征空间里，GAN 生成的伪影噪点和真实的纹理细节没有本质区别（都是高频信息）。因此，LoRA 微调很难扭转这种像素级相关性的惯性。ViT 的局限：监督学习的分类头让特征高度抽象化，丢弃了大量利于检测伪影的底层空间信息。

指标定义与物理含义：

Intra-Real (类内-真)： 真实图像样本间的平均余弦相似度。该值越高，表示真实样本在特征空间中的分布越紧凑。

Intra-Fake (类内-假)： 伪造图像样本间的平均余弦相似度。该值反映了模型提取的伪造特征在不同生成器（如 BigGAN 与 DeepFake）间的一致性。

Inter(R-F) (类间-真假)： 真实样本中心与伪造样本中心之间的余弦相似度。该值越低（甚至为负），表示真假两类在特征空间中的距离越远，正交性或对立性越强。

Gap (分离度)： 计算公式为 $\text{Intra(Avg)} - \text{Inter(R-F)}$ 。该指标综合衡量了类内紧凑度与类间分离度，直接反映了线性分类边界的构建难度

Model Configuration	Intra(Real)	Intra(Fake)	Intra(Avg)	Inter(R-F)	Gap (Sep)
DINOv2 (Base)	0.0247	0.0683	0.0465	0.0303	0.0163
DINOv2 (LoRA)	0.4466	0.2673	0.3569	-0.0402	0.3971
DINOv3 (Base)	0.0198	0.0852	0.0525	0.0226	0.0299
DINOv3 (LoRA)	0.9732	0.3933	0.6833	-0.5987	1.2820
CLIP (Base)	0.2631	0.3307	0.2969	0.2547	0.0422
CLIP (LoRA)	0.4174	0.4506	0.4340	0.0990	0.3350
BLIP (Base)	0.6115	0.6673	0.6394	0.6359	0.0035
BLIP (LoRA)	0.6884	0.3351	0.5118	0.1477	0.3640
MAE (Base)	0.8706	0.8853	0.8780	0.8763	0.0017
MAE (LoRA)	0.9487	0.3092	0.6289	0.1903	0.4386
ViT (Base)	0.0653	0.0748	0.0700	0.0671	0.0029
ViT (LoRA)	0.6047	0.1082	0.3564	0.1722	0.1842

在 Test (biggan, cyclegan 等) 上测试真假图余弦相识度

DINOv3/DINOv2：

数据观察： DINOv3 (LoRA) 的 Intra(Real)达到了最高的 0.9732，且 Inter(R-F) 达到了-0.5987。其 Gap 1.2820 是所有模型中唯一的量级突破。

性能解释： 相比 DINOv2 的 0.4466，DINOv3 几乎将所有真实图像收缩到了特征空间的一个点上。其 Inter(R-F)为负值，说明在微调后，真图中心与假图中心在特征向量方向上呈现完全背离的状态。这种极致的“排斥策略”使其对扩散模型产生的细微纹理离群点极度敏感，解释了其在 Uni 测试集上的优异表现

CLIP：

数据观察： CLIP (LoRA)的 Intra(Fake)达到 0.4506，不仅是所有模型中最高的，且超过了其自身的 Intra(Real) (0.4174)。

性能解释： 这证明了 CLIP 学习到了真正的“通用伪造概念”。得益于大规模图文对齐先验，CLIP 微调后不仅是排斥假图，更是主动将来自不同生成器的伪造图像聚类在

一起。这种高度一致的伪造特征簇使其在面对未见过的 GAN 架构（如 9GAN）时具备最强的鲁棒性。

BLIP、MAE 与 ViT 的局限性

BLIP:

数据: BLIP (LoRA) 的指标处于中游, Inter(R-F) 0.1477 仍处于较高正值。

解释: BLIP 的生成式目标迫使模型关注宏观语义以生成文本。为了描述“一只猫”, 模型会自动过滤掉不影响语义的高频噪声。然而, 这些被过滤的噪声恰恰是取证所需的关键信号, 导致真假样本的类间分离度受限。

MAE:

数据: MAE (LoRA) 虽然 Intra(Real) 极高 (0.9487), 但其 Inter(R-F) 依然高达 0.1903 (正相关)。

解释: 极高的 Intra(Real) 说明 MAE 微调后几乎把所有真实图片都压缩到了一个极小的点上。这是一种典型的过拟合迹象——模型死记硬背了真实图片的像素统计规律。然而, 它对假图的聚类能力平平, 说明它并没有学会“什么是假”, 只是记住了“什么是真”, 这导致其在面对未见过的生成器（如扩散模型）时极易失效。

ViT :

数据: ViT (LoRA) 的 Intra(Fake) 仅为 0.1082, 几乎处于随机分布状态。

解释: ViT 的低 Intra(Fake) 表明, 它无法将不同类型的伪造样本（如 BigGAN 和 StyleGAN）归纳为同一类。在 ViT 眼里, 不同的假图是完全不同的东西, 它们之间没有共性。这证实了纯监督分类产生的特征空间过于刚性, 缺乏对“伪造”这一抽象概念的建模能力, 导致微调时特征空间无法有效重组。

结论总结: 通过这份表格, 验证了本研究的一个核心 Contribution: 优秀的伪造检测器必须具备在保持语义锚点的同时, 实现特征空间的极度非线性重塑。

三：检索可视化实验的深入

对于检索图中，不仅匹配找到多少假图还要看他们中找到的图中有多少是和检索图一个类别的（还没做，不知道是否可行）

CLIP/DINOv3（理想状态-语义与伪影共存）：

Frozen：检索出同类别的物体（车→车）。

LoRA：检索出同类别的伪造物体（假车→假车，假猫→假猫）。

分析：模型成功将关注点聚焦在“车身上的伪影”，同时保留了“车”的结构。这是泛化能力的来源。

MAE（理想情况-语义坍塌）：

Frozen：检索结果主要是基于像素颜色和轮廓的相似性，语义性已然不强。

LoRA：检索结果彻底崩坏。查询“车”，返回的是“人”、“床”等。

深入分析：这表明 MAE 在被迫学习“真/假”二分类时，为了寻找区分边界，彻底牺牲了原有的特征结构。它找到了一些极其底层的，可能是某种特定的噪声频率，导致特征空间中“车”和“床”等因为具有相同的噪声模式而被聚在一起。这种特征极其脆弱，换一个生成器（如从 9GAN 换到 Diffusion），这种统计规律失效，模型性能大幅下滑（见 MAE-9GAN/Uni 数据）。

ViT :LoRA：检索结果虽然还是物体，但类别经常跑偏。说明全监督的 ViT 特征过于刚性，LoRA 微调难以在不破坏原有分类边界的情况下嵌入伪造特征。

通过我目前做的基础检索图，确实能简单证明上述这一点。

四. 为什么现在很多用 DINO

1. DINOv3 能够捕捉“全局一致的低频结构”。

解释：生成图像往往在光影、透视关系等长距离依赖上存在细微的物理不一致。

DINOv3 能够忽略局部的高频纹理，转而关注全局的物理结构。

对比：CLIP 模型可能过于关注语义（这是一只猫），而 DINOv3 关注的是物理规律（这只猫的光影是否符合物理逻辑）。

2. 模型大

论文 (Rethinking Cross-Generator)：图表显示 DINOv2 随着模型增大提升有限，但 DINOv3 呈现显著的 Scaling Law。特别是 ViT-7B 版本，性能有质的飞跃。

推测：我的实验中用的 DINOv3 是 Large 版本，而非 Huge 或 7B（我的显卡不足）。在较小规模下，DINOv3 的优势不如 CLIP 的语义先验明显；但一旦上到超大规模，纯视觉模型的“物理世界建模能力”就会超越 CLIP 的“语义对应能力”。

3. 抗干扰与鲁棒性

论文 (DINO-Detect)：论文证明在模糊等退化条件下，DINOv3 比 CLIP 更稳健。

原因：CLIP 依赖清晰的语义特征。如果图像模糊，语义特征受损，CLIP 性能下降。而 DINOv3 学习的是底层的视觉一致性，对模糊等退化有更强的本身鲁棒性

准备补充实验：

实验 1：频率/结构破坏实验

目的：验证 CLIP 靠语义，DINOv3 靠结构。

操作：将图片切成 4x4 或 8x8 的块并打乱位置（破坏全局结构，保留局部语义和纹理）。仅保留高频边缘（破坏语义和结构，保留纹理伪影）。

预期结果：

DINOv3 在 Block Shuffle 下性能应大幅下降。**CLIP** 可能下降较少（因为打乱的块依然包含“猫”的局部特征，CLIP 的词袋模型属性可能仍能识别语义）。

这在论文 (Rethinking Cross-Generator) 已经证明 dinov3 确实会下降。

实验 2：模糊与退化测试

目的：证明 DINOv3 在恶劣环境下的潜力。

操作：对测试集施加高斯模糊或运动模糊。


预期结果：DINOv3 的性能衰减曲线应比 CLIP 更平缓。这在论文（DINO-Detect: A Simple）已经证明 dinov3 适合做模糊、真实世界的检测。同样能证明为什么 mae 和 dinov3 指标相同但是效果差距很大。

五. 目前疑问：

1. 数据增强中需要旋转，高斯模糊，颜色抖动等吗？
2. Resize 还是 crop（mae 使用 crop 后 test 上有所上升但到了 9gan 上还是下降）
3. 最后送入 classifie 的 features, 是用 cls 或 patch（均值），还是都用？（以前用的是汇聚层除 mae, vit 后续进行了调整）
4. 补充实验的角度是否可行

BLIP, MAE, VIT 可视化检索实验:

BLIP:



MAE:

Processing Query Image...

Processing Database Images...

Extracting features for 2000 images (Frozen)

Processed 500/2000

Processed 1000/2000

Processed 1500/2000

Processed 2000/2000

Extracting features for 2000 images (LoRA)

Processed 500/2000

Processed 1000/2000

Processed 1500/2000

Processed 2000/2000

Running Visual Search...

=== Debug Analysis for Frozen MAE (Baseline)

Global Avg Sim with REAL: 0.8692

Global Avg Sim with FAKE: 0.8804

--- Top-N Distribution (Frozen MAE (Baseline)) ---

Top- 10: Real= 2 | Fake= 8

Top- 50: Real= 17 | Fake= 33

Top-100: Real= 38 | Fake= 62

Saving Frozen MAE (Baseline) result to search_result_mae_frozen.png

=== Debug Analysis for LoRA MAE (Ours) ===

Global Avg Sim with REAL: 0.9454

Global Avg Sim with FAKE: 0.2669

--- Top-N Distribution (LoRA MAE (Ours)) ---

Top- 10: Real= 10 | Fake= 0

Top- 50: Real= 49 | Fake= 1

Top-100: Real= 99 | Fake= 1

Saving LoRA MAE (Ours) result to search_result_mae_lora_mae.png...

Model: Frozen MAE (Baseline) Target Search Analysis (MAE)



Model: LoRA MAE (Ours) Target Search Analysis (MAE)



Processing Database Images...

Extracting features for 2000 images (Frozen)...

Processed 500/2000

Processed 1000/2000

Processed 1500/2000

Processed 2000/2000

Extracting features for 2000 images (LoRA)...

Processed 500/2000

Processed 1000/2000

Processed 1500/2000

Processed 2000/2000

Running Visual Search...

=== Debug Analysis for Frozen MAE (Baseline) ===

Global Avg Sim with REAL: 0.8718

Global Avg Sim with FAKE: 0.8798

--- Top-N Distribution (Frozen MAE (Baseline)) ---

Top- 10: Real= 4 | Fake= 6

Top- 50: Real= 20 | Fake= 30

Top-100: Real= 42 | Fake= 58

Saving Frozen MAE (Baseline) result to search_result_ma

=== Debug Analysis for LoRA MAE (Ours) ===

Global Avg Sim with REAL: -0.7249

Global Avg Sim with FAKE: 0.0216

--- Top-N Distribution (LoRA MAE (Ours)) ---

Top- 10: Real= 0 | Fake= 10

Top- 50: Real= 0 | Fake= 50

Top-100: Real= 0 | Fake= 100

Saving LoRA MAE (Ours) result to search_result_mae_lora_mae.png...


Model: Frozen MAE (Baseline) Target Search Analysis (MAE)



Model: LoRA MAE (Ours) Target Search Analysis (MAE)




VIT:




测试数据:


Blip:



Dinov3:



MAE:



VIT:

